

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: Trump's Truth Social Scraper & Sentiment Analyzer (Automatyczne pobieranie tweetów oraz wielosłownikowa analiza sentymentu i tematów w języku angielskim)

Wersja dokumentu: 1.0

Data: 03.06.2026

Autor: [Aleksander Pacholski, Zuzanna Rafał, Karolina Drapała]

1. Wprowadzenie:

Niniejszy dokument opisuje specyfikację wymagań dla zintegrowanego systemu napisanego w języku R, którego celem jest pobieranie (scrapowanie) wpisów z platformy Trump's Truth Social (trumpstruth.org) w wybranym przedziale czasowym, ich filtracja chronologiczna oraz zapis, a następnie przeprowadzenie pełnej analizy text mining i analizy sentymentu. System łączy techniki web scrapingu z tradycyjnymi metodami czyszczenia tekstu, tokenizacji, stemmingu oraz uzupełniania rdzeni (typ prevalent). Ocena emocjonalna realizowana jest wielopoziomowo przy użyciu zewnętrznych słowników CSV (AFINN, Bing, NRC, Loughran), a także słowników z pakietu SentimentAnalysis (GI, HE, LM, QDAP). Dodatkowo generowane są wizualizacje częstości słów w postaci chmury słów, wykresów rodzaju sentymentu wg słowników oraz wykresów zmiany sentymentu w czasie.

2. Cele systemu:

- Automatyczne pobieranie wpisów z platformy trumpstruth.org dla zadanego przez użytkownika zakresu dat z wykorzystaniem stronicowania (paginacji) i eksport wyników do pliku .txt.
- Wczytanie wygenerowanego tekstu wejściowego (plik .txt) z odpowiednim kodowaniem (UTF-8).
Usunięcie nieistotnych słów (stopwords).
Przetwarzanie i oczyszczanie tekstu (normalizacja znaków apostrofów, konwersja na małe litery, usuwanie interpunkcji, liczb, tokenów z apostrofami oraz tokenizacja).
- Zliczenie częstości występowania słów oraz ich wizualizacja w formie chmury oraz wykresu słupkowego 20 najczęstszych słów.
- Przeprowadzenie analizy sentymentu z użyciem słowników:
 - o w plikach CSV (AFINN, Bing, NRC, Loughran).
 - o wbudowanych w pakiet SentimentAnalysis (GI, HE, LM, QDAP)
- Wizualizacja wyników sentymentu (skumulowany sentyment oraz ewolucja nastroju w czasie / per segment).
- Wyświetlenie w konsoli ustrukturyzowanego raportu końcowego zawierającego podsumowanie tematyczne oraz statystyki sentymentu.

3. Wymagania funkcjonalne:

• Wczytywanie danych:

- o Skrypt powinien umożliwiać automatyczne pobieranie danych za pomocą zapytania HTTP z paginacją ze strony trumpstruth.org w zadanym zakresie dat, odrzucając wpisy zawierające tylko multimedia (is_media_only) i zapisując je chronologicznie do lokalnego pliku .txt.
- o Skrypt powinien obsługiwać kodowanie UTF-8.

• Przetwarzanie i oczyszczanie tekstu:

- o Skrypt powinien umożliwiać normalizację apostrofów na apostrof klasyczny.
- o Skrypt powinien umożliwiać usunięcie liczb, interpunkcji oraz form skróconych zawierających apostrofy.

- o Skrypt powinien umożliwiać usunięcie pustych elementów oraz zbędnych znaków specjalnych.

- o Skrypt powinien umożliwiać usunięcie stopwords z pakietów tidytext i tm.

- o Skrypt powinien umożliwiać wykonanie stemmingu i uzupełnienia rdzeni słów.

- **Analiza częstości:**

- o Skrypt powinien umożliwiać zliczenie liczby wystąpień słów.

- o Skrypt powinien umożliwiać posortowanie słów według częstości i automatyczne wskazanie głównego tematu.

- o Skrypt powinien umożliwiać przedstawienie wyników w formie tabeli i chmury słów.

- **Analiza sentymentu (słowniki w plikach CSV):**

- o Skrypt powinien umożliwiać wczytanie słowników: afinn.csv, bing.csv, nrc.csv, loughran.csv.

- o Skrypt powinien umożliwiać dopasowanie słów do słowników i zliczenie sentymentów (w tym obliczenie łącznego wyniku numerycznego dla AFINN).

- o Skrypt powinien umożliwiać filtrowanie słów o sentymencie pozytywnym lub negatywnym oraz analizę kontekstową sentymentu bezpośrednio wokół słów kluczowych.

- **Analiza sentymentu (słowniki wbudowane w pakiet SentimentAnalysis):**

- o Skrypt powinien przeprowadzać analizę sentymentu tekstu z wykorzystaniem biblioteki SentimentAnalysis.

- o Skrypt powinien wykorzystywać słowniki GI, HE, LM, QDAP.

- o Skrypt powinien konwertować ciągłe wartości sentymentu na kategorie kierunkowe.

- o Skrypt powinien umożliwiać podział tekstu na segmenty o ustalonej długości za pomocą dedykowanej funkcji dzielenia korpusu.

- **Wizualizacja danych:**

- o Skrypt powinien umożliwiać wizualizację wyników (wykresy ggplot2).

- o Skrypt powinien generować wykresy skumulowanego sentymentu dla każdego słownika w postaci paneli (facet_wrap).

- o Skrypt powinien generować wykres porównujący sentyment na podstawie różnych słowników.

- o Skrypt powinien generować wykresy przedstawiające ewolucję sentymentu w czasie (wykresy liniowe i wygładzone).

- **Agregacja danych:**

- o Skrypt powinien agregować sentyment z różnych słowników w jednej ramce danych z podziałem na segmenty osi czasu.

- o Skrypt powinien usuwać brakujące wartości (NA).

4. Wymagania нефunkcjonalne:

- **Wydajność:**

- o Analiza pliku o długości 1000 zdań powinna trwać nie dłużej niż 15 sekund (nie wliczając czasu pobierania danych z sieci przez żądania HTTP).

- o Czas pobierania pojedynczej strony danych przez scraper nie powinien przekraczać 2 sekund przy stabilnym połączeniu sieciowym.

- **Bezpieczeństwo:**

- o System powinien zapewnić poprawność danych wyjściowych, stosując bloki tryCatch w celu ignorowania uszkodzonych rekordów lub błędów parsowania pojedynczych postów bez zatrzymywania działania programu.

- **Niezawodność:**

- o Skrypt powinien poprawnie obsługiwać różne formaty danych tekstowych oraz błędy pobierania sieciowego.

- o Skrypt powinien poprawnie obsługiwać brakujące wartości.

- **Użyteczność:**

- o Wykresy powinny być czytelne i zawierać odpowiednie etykiety.

- o Skrypt powinien umożliwiać wykonanie wizualizacji z użyciem ggplot2 i motywu theme_gdocs dla lepszej czytelności.

- o Skrypt powinien umożliwiać generowanie chmury słów z wykorzystaniem kolorystyki RColorBrewer.

- **Kompatybilność:**

- o Skrypt powinien być kompatybilny z R w wersji 4.0 lub nowszej.

- o Skrypt powinien korzystać z bibliotek httr2, xml2, dplyr, tibble, lubridate, stringr, tm, tidytext, wordcloud, RColorBrewer, ggplot2, SnowballC, SentimentAnalysis, ggthemes, tidyverse.

5. Interfejsy użytkownika:

- **Wejście:**

- o Parametry start_date i end_date podawane przez użytkownika.

- o Pliki słowników w formacie .csv (afinn.csv, bing.csv, nrc.csv, loughran.csv).

- **Wyjście:**

- o Tabela z częstością występowania słów i automatycznie wskazany główny temat.

- o Chmura słów (wordcloud).

- o Wykresy słupkowe rodzaju sentymentu wg słowników (AFINN, Bing, NRC, Loughran, GI, HE, LM, QDAP).

- o Wykresy zmian sentymentu w czasie (liniowe i wygładzone) oraz automatyczny tekstowy RAPORT KOŃCOWY w konsoli.

6. Wymagania dotyczące danych:

- Skrypt zakłada, że dane tekstowe są w języku angielskim.

- Skrypt nie obsługuje analizy sentymentu dla innych języków.

- Skrypt wykorzystuje słowniki sentymentów dostępne w plikach .CSV oraz w pakiecie SentimentAnalysis.

- Skrypt nie obsługuje analizy sentymentu dla danych tekstowych z innych źródeł niż pliki tekstowe pobrane z platformy lub pliki .txt o analogicznej strukturze.

- Skrypt nie obsługuje plików o rozmiarze powyżej 100 MB.

Słownictwo dokumentacji:

- Token: pojedynczy element tekstu (słowo).

- Stopwords: słowa niewnoszące wartości semantycznej do analizy.

- Sentyment: emocjonalne nastawienie w tekście.

- Słownik sentymentów: lista słów i ich ocen wg sentymentu.

- Skumulowany sentyment: suma ocen sentymentu dla całego tekstu.

- Wartości kierunkowe: konwersja ciągłych wartości sentymentu na kategorie (np. pozytywny, negatywny, neutralny).

- Ewolucja sentymentu: zmiana sentymentu w czasie (wzdłuż czasu narracyjnego lub segmentów czasu wpisów).

- Stem: forma słowa po sprowadzeniu go do rdzenia.

- Stem Completion: uzupełnienie rdzenia słowa po stemmingu.

- Scraper: moduł służący do automatycznego pobierania i strukturyzowania danych ze stron internetowych.

Przypadki użycia (use cases)

- **Użytkownik:**

- podaje zakres dat i uruchamia pobieranie
- uruchamia analizę text mining
- wyświetla wyniki w konsoli
- generuje wykresy i raport html

- **Skrypt/system:**

- wysyła zapytania z paginacją do portalu i filtruje multimedia
- przetwarza i oczyszcza tekst z pliku truth_tweets.txt
- analizuje sentyment tekstu przy użyciu słowników CSV i SentimentAnalysis
- generuje chmurę słów i wykrywa główny temat
- generuje wykresy skumulowanego sentymentu
- generuje wykres porównujący rodzaj sentymentu wg słowników
- generuje wykresy zmiany sentymentu w czasie segmentów
- drukuje sformatowany raport końcowy podsumowujący podejście autora

Testowe przypadki użycia:

- Test z zakresem dat zwracającym wpisy o silnie pozytywnym sentymencie.
- Test z zakresem dat zwracającym wpisy o silnie negatywnym sentymencie.
- Test z zakresem dat zwracającym wpisy o neutralnym sentymencie.
- Test z plikiem zawierającym posty o mieszanym i zmiennym sentymencie w czasie.
- Test z zakresem dat nie zawierającym żadnych wpisów (pusty wynik i komunikat systemu).
- Test z wpisami zawierającymi wyłącznie znaki specjalne, emoji i linki (is_media_only).

Scenariusze użytkownika (user stories)

Scenariusz 1: Przewidywanie posunięć politycznych na potrzeby rynków finansowych

- Jako: Traderka na giełdzie/rynkach predyktywnych
- Chcę: Automatycznie pobrać wpisy Donalda Trumpa z wybranego przedziału czasowego i poddać je analizie text mining
- Aby: Przewidzieć posunięcia Białego Domu na podstawie trendów w sentymencie, żeby wykorzystać przewagę informacyjną do zarobku

Kryteria akceptacji:

- Użytkownik może określić daty startowe i końcowe dla pobierania danych.
- Skrypt przeprowadza analizę sentymentu za pomocą różnych słowników.
- Skrypt generuje wykresy skumulowanego sentymentu i porównuje wyniki z różnych słowników.
- Skrypt generuje wykresy ewolucji sentymentu w czasie.
- Użytkownik może zidentyfikować ogólny sentyment wpisów i obszary zmian, które pozwalają uzyskać przewagę informacyjną.

Scenariusz 2: Badanie wpływu koniunktury gospodarczej na retorykę polityczną

- Jako: Analityk ekonomii politycznej
- Chcę: Monitorować sentyment we wpisach autora
- Aby: Zbadać wpływ koniunktury na narrację Trumpa.

Kryteria akceptacji:

- Użytkownik może wczytać dane tekstowe z mediów społecznościowych do pliku tekstowego.
- Skrypt przeprowadza analizę sentymentu i generuje wykresy ewolucji sentymentu w czasie.
- Użytkownik może monitorować zmiany sentymentu.
- Użytkownik może identyfikować nagłe zmiany sentymentu i reagować na nie.
- Użytkownik może generować raporty z analizy sentymentu.

Scenariusz 3: Analiza wywiadowcza i prognozowanie geopolityczne

- Jako: Analityczka w MSZ lub agencji wywiadowczej innego kraju
- Chcę: Przeanalizować wpisy autora w celu określenia dominujących emocji
- Aby: Przewidzieć kolejne posunięcia rządów Stanów Zjednoczonych i w ten sposób wesprzeć skuteczną politykę zagraniczną swojego rządu.

Kryteria akceptacji:

- Użytkownik może wczytać plik tekstowy z treścią wpisów.
- Skrypt przeprowadza analizę sentymentu za pomocą różnych słowników.
- Skrypt generuje chmurę słów.
- Skrypt generuje wykresy skumulowanego sentymentu i porównuje wyniki z różnych słowników.
- Skrypt generuje wykresy ewolucji sentymentu w czasie.
- Użytkownik może zidentyfikować sentymenty dominujące w narracji autora w celu dokonania pogłębionej analizy naukowej i wsparcia polityki zagranicznej.